



GUSła

PRÓBKOWANIE Z WARSTWAMI

STANISŁAW FRELIK
ALEKSANDRA KULCZYCKA





01

WSTĘP

02

LITERATURA

03

CELE

04

PRÓBKOWANIE JEDNOSTOPNIOWE Z WARSTWAMI

05

PRÓBKOWANIE DWUSTOPNIOWE Z WARSTWAMI

06



PODSUMOWANIE

01

WSTĘP

Teoria próbkowania jest kluczowa dla rzetelnej i skutecznej praktyki statystycznej, a optymalna alokacja próbki w modelu 'z warstwami' to złożony problem metodologiczny.





02

LITERATURA

[1] **J. Wesołowski, R. Wieczorkowski, W. Wójciak**

'Recursive Neyman algorithm for optimum sample allocation under box constraints on sample sizes in strata'

[2]

W. Niemirow, J. Wesołowski

'Fixed precision optimal allocation in two-stage sampling'

03

CELE

π -estymator


Przeanalizujemy minimalizację wariancji π -estymatora za pomocą symulowanego wyżarzania.

1 poziom

Omówimy jednopoziomowe próbkowanie warstwowe


2 poziomy

Omówimy próbkowanie dwupoziomowe gdy 'nadpopulacja' również posiada warstwy.



**04 PRÓBKOWANIE
JEDNOPOZIOMOWE**





MODEL ALOKACJI SZKÓŁ W WOJEWÓDZTWACH

- **Warstwy:** Województwa (rozłączne, niepuste, pokrywające populację szkół)
- **Alokacja:** Dowolny wybór szkół z zachowaniem liczebności w danym województwie
- **Ograniczenia:** Liczba szkół w województwie jest ustalona
- **Dane:** Współczynniki wariancji dla każdej warstwy (województwa)

W tym kontekście rozważamy π -estymator całkowitej (lub średniej) wartości interesującej nas cechy charakteryzującej populację szkół. Istotną cechą tego estymatora jest jego nieobciążoność.


Chcielibyśmy zminimalizować wariancję tego estymatora, aby uzyskać **optymalną alokację**.




- H - liczba warstw charakteryzująca rozważaną populację
- A_h - znane współczynniki wariancji w każdej z warstw ($h = 1, \dots, H$)
- x_h - liczba elementów z warstwy h wybrana do próbki
- M_h - całkowita liczba elementów w h -tej warstwie
- m_h - dolne ograniczenie na liczbę elementów wybranych do próbki z h -tej warstwy
- n - ustalona wielkość próbki

$$\min_{\mathbf{x}=(\mathbf{x}_h)_{h=1}^H} \sum_{h=1}^H \frac{A_h^2}{x_h}$$

przy ograniczeniach: $\sum_{h=1}^H x_h = n$ oraz $\forall_h m_h \leq x_h \leq M_h$





ROZWIĄZANIE:

229

400

604

51



OPTYMALNE ROZWIĄZANIE Z ALGORYTMU RNABOX:

228.9496

400.0000

604.1727



50.8777




ROZWIĄZANIE:

90 100 76 70 127 480 580 610 235 632


OPTYMALNE ROZWIĄZANIE Z ALGORYTMU RNABOX: 90.00 100.00 76.125 70.00 126.875 480.00 580.00 610.00 235.00 632.00



Wykres funkcji celu



Wykres trajektorii wartości dążących do optymalnej alokacji





05

PRÓBKOWANIE DWUPOZIOMOWE

MODEL ALOKACJI SZKÓŁ W WOJEWÓDZTWACH

- **Warstwy:**
 - Województwa (podobnie jak w modelu jednopoziomowym)
- **Dodatkowe założenia:**
 - W każdej szkole znana (ustalona) liczba uczniów.
 - Cecha, którą chcemy estymować, jest obserwowana u uczniów.
- **Alokacja polega na:**
 - Wyborze ustalonej liczby szkół z poszczególnych województw (z uwzględnieniem ograniczeń górnych i dolnych).
 - Wyborze pewnej liczby uczniów z każdej szkoły (z uwzględnieniem ograniczeń wynikających z liczebności uczniów w danej szkole).

MODEL ALOKACJI SZKÓŁ W WOJEWÓDZTWACH

- **Dane:**

- Współczynniki wariancji dla warstw i poszczególnych szkół.
- Estymator liczby uczniów, która powinna odpowiadać pierwszemu poziomowi alokacji (liczba wybranych uczniów zależy od wyboru liczby szkół w województwach).




ZAŁÓŻMY, ŻE
MAMY PEWNĄ
ALOKACJĘ –
PUNKT
STARTOWY




ZAŁÓŻMY, ŻE
MAMY PEWNĄ
ALOKACJĘ –
PUNKT
STARTOWY

NASTĘPNIE
PROponujemy
ZARÓWNO KROK
NA POZIOMIE
“PIERWOTNYM”
JAK I “WTÓRNYM”



JP (JEDNOSTKI
PIERWOTNE)

JW (JEDNOSTKI
WTÓRNE)



Na podstawie [2] mamy:


- $V = W_1 + \dots + W_H$ - populacja podzielona na warstwy
- $\#(W_h) = M_h$ - liczba JP w h -tej warstwie ($h = 1, \dots, H$)
- m_h - liczba JP wybranych do próbki z h -tej warstwy
- $U_{h,j}$ - j -ta JP z h -tej warstwy
- $\#(U_{h,j}) = N_{h,j}$ - liczba JW w j -tej JP z h -tej warstwy
- $n_{h,j}$ - liczba JW wybranych do próbki z j -tej JP z h -tej warstwy (pod warunkiem wybrania $U_{h,j}$ do próbki)
- $N_h = \sum_{j \in W_h} N_{h,j}$

$$D^2(\hat{t}) = \sum_{h=1}^H \left(\frac{1}{m_h} - \frac{1}{M_h} \right) M_h^2 D_h^2 + \sum_{h=1}^H \frac{M_h}{m_h} \sum_{j=1}^{M_h} \left(\frac{1}{n_{h,j}} - \frac{1}{N_{h,j}} \right) N_{h,j}^2 S_{h,j}^2$$

$$t_{h,j} = \sum_{u \in U_{h,j}} y_{h,j,u}, \quad \bar{y}_{h,j} = \frac{t_{h,j}}{N_{h,j}} \quad \text{oraz} \quad \bar{t}_h = \frac{\sum_{j=1}^{M_h} t_{h,j}}{M_h}$$

$$S_{h,j}^2 = \frac{1}{N_{h,j}-1} \sum_{u \in U_{h,j}} (y_{h,j,u} - \bar{y}_{h,j})^2, \quad D_h^2 = \frac{1}{M_h-1} \sum_{j=1}^{M_h} (t_{h,j} - \bar{t}_h)^2$$

$$\sum_{h=1}^H \frac{m_h}{M_h} \sum_{j=1}^{M_h} n_{h,j} = n$$





ZAŁÓŻMY, ŻE
MAMY PEWNĄ
ALOKACJĘ –
PUNKT
STARTOWY

NASTĘPNIE
PROPONUJEMY
ZARÓWNO KROK
NA POZIOMIE
“PIERWOTNYM”
JAK I “WTÓRNYM”

MAMY ZATEM
DWÓCH
KANDYDATÓW.
ROZWAŻAMY TERAZ
PRZYPADKI
WYNIKAJĄCE Z
ALGORYTMU
SYMULOWANEGO
WYŻARZANIA



ZAŁOŻMY, ŻE
MAMY PEWNĄ
ALOKACJĘ –
PUNKT
STARTOWY


NASTĘPNIE
PROPONUJEMY
ZARÓWNO KROK
NA POZIOMIE
“PIERWOTNYM”
JAK I “WTÓRNYM”

MAMY ZATEM
DWÓCH
KANDYDATÓW.
ROZWAŻAMY TERAZ
PRZYPADKI
WYNIKAJĄCE Z
ALGORYTMU
SYMULOWANEGO
WYŻARZANIA


PRZECHODZIMY
DO JEDNEJ Z
ALOKACJI LUB
ZOSTAJEMY W
MIEJSCU

PORÓWNANIA

- zestawienie wyniku algorytmu z teoretycznym wynikiem uzyskanym w pracy [2], dotyczącym przypadku **bez** naturalnych **ograniczeń**.
- Nasza optymalizacja dotyczy mniejszego zbioru z ograniczeniami.
- Jeśli uzyskany wynik będzie zbliżony do teoretycznego, będzie to świadczyło o jego wysokiej jakości.



Zmiana wartości funkcji celu w czasie



Uzyskana alokacja na poziome JP:

35 37 33 41 54

Optymalna alokacja na poziomie JP:

37.51 38.91 34.71 42.88 45.99

Optymalna wariancja: **24704649**

Uzyskana wariancja: **24726833**

PRZYKŁAD

- Rozmiar pierwotnej populacji:
35, 40, 50, 70, 150, 50, 30, 55, 200, 450, 50, 70, 130, 150, 200
- Maksymalny rozmiar wtórnej populacji: 250
- Ustalony rozmiar próbki: 500

PRZYKŁAD CD.


Uzyskana alokacja na poziome JP:

23 25 25 31 38 28 21 26 48 47 24 33 41 43 47

Optymalna alokacja na poziome JP:

22.64 24.60 25.38 30.63 38.96 28.28 20.90 26.07 47.84 45.47 24.23 32.79 40.71 44.06 47.36

PRZYKŁAD CD.



Optymalna wariancja: **$2.302778e+12$**

Uzyskana wariancja: **$2.296735e+12$**

Błąd względny: **0.262%**


Wystymowana liczba elementów
wtórnych: **23101**

Optymalna liczba elementów wtórnych:
114349.8


Błąd alokacji na poziomie wtórnym: **5102**

PRZYKŁAD CD.

Zmiana “nacisku selekcji” wraz z
postępem wyżarzania



PRZYKŁAD CD.



PODSUMOWANIE

Uzyskane wyniki charakteryzują się satysfakcjonującym poziomem zarówno pod względem jakości, jak i efektywności wypracowanych rozwiązań. Należy jednak zaznaczyć, że omawiane zagadnienia wymagają dalszych badań.

Zastosowane rozwiązanie algorytmiczne problemu drugiego posiada duży potencjał do optymalizacji. Udoskonaleniom podlegać mogą nie tylko komponenty "wyżarzające", ale również konstrukcja danych stanowiących ich fundament.



05

PODSUMOWANIE

Budowanie zaangażowania i więzi emocjonalnej z omawianą problematyką stanowi kluczowy czynnik warunkujący satysfakcję z prowadzonych badań.

Bez zaangażowania i pasji badawczej, problematyka staje się jedynie zbiorem liter i cyfr, tracąc swój potencjał odkrywczy.



**DZIĘKUJEMY
ZA UWAGĘ**

